CDMC · 方法导读

从 PDE 到 128 维响应空间：方法逐步解释

配合论文方法节与 `refinement/core.py` 阅读

2026-11-05 | 阅读约 25 分钟 | 目标：把每个公式的来历、符号含义与作用讲清楚

0 五个对象 1 离散系统 2 残差即误差 3 总体策略 4 滤波 5 响应字典 6 校准 7 去偏
8 多轮复用 9 训练 10 覆盖率 11 成本 12 公式地图 13 代码对应

0 先记住五个对象和一条恒等式

符号	含义	规模
A	刚度矩阵，由当前材料 a 装配	N×N，N = 65,025（257^2 网格）
b	载荷向量（源项与边界提升）	N
x*	参考解（离散方程的真解）	N
x	当前近似解（神经算子预测，或某轮校正后的解）	N
r = b − Ax	残差：当前解在方程上的“亏损”	N

离散方程是

$$A\,x^* = b$$

由此立刻得到整篇文章的出发点：

$$A(x^* - x) = b - Ax \quad\Longrightarrow\quad A\,e = r, \quad e := x^* - x$$

这条恒等式说的是：**残差不是误差的“代理指标”，它就是误差经过 A 变换后的结果**。想得到误差，就要解一个和原问题同规模的方程 Ae = r，这等于把原问题再解一遍。方法的所有设计，都是为了**不解这个方程，又能把 e 近似出来**。

一句话：残差是误差的另一种写法；方法的目标是用很小的代价把 e 从 r 里“反推”出来。

1　从 PDE 到线性系统：A 和 b 是怎么来的

原方程

$$-\nabla\cdot(a\nabla u) = f \quad \text{in } \Omega, \quad u = g \quad \text{on } \partial\Omega$$

两边乘测试函数 v（边界上为 0），分部积分：

$$\int_\Omega a\,\nabla u\cdot\nabla v\,d\xi = \int_\Omega f\,v\,d\xi$$

把边界条件写成 $u = u_g + w$，w 在边界为 0，得到弱形式：

$$\int_\Omega a\,\nabla w\cdot\nabla v\,d\xi = \int_\Omega f\,v\,d\xi - \int_\Omega a\,\nabla u_g\cdot\nabla v\,d\xi$$

在三角网格上用 P1 基函数 ϕ_i，令 $w_h = \Sigma_i\, x_i\phi_i$，逐个用 ϕ_j 测试：

$$A_{ij} = \int_\Omega a\,\nabla\varphi_i\cdot\nabla\varphi_j\,d\xi, \qquad b_j = \int_\Omega f\,\varphi_j\,d\xi - \int_\Omega a\,\nabla u_g\cdot\nabla\varphi_j\,d\xi$$

符号在做什么：

- A_{ij}：基函数 i 与 j 之间的“能量耦合”，只由材料 a 和网格几何决定；
- b_j：源项在第 j 个基函数上的投影，减去边界提升的贡献；
- 正系数 $a > 0$ 保证 $A = A^T$ 正定，这是后面所有能量论证的前提。

实际装配不需要做积分：P1 基函数在三角形上是线性的，梯度为常量，单元刚度矩阵有闭式

$$A^T_{ij} = |T|\,a_T\,\nabla\varphi_i|_T\cdot\nabla\varphi_j|_T$$

其中 a_T 是三个节点材料值的平均。网格几何与稀疏结构预先生成一次，换材料时只重算 a_T 与这些数。

> **一句话：** A 是材料在离散层面的全部信息；换材料就是换 A，其他都不变。

2　为什么不能直接解 Ae = r

能解，但代价和原问题一样：一次完整的细网格求解。方法要面对的是“材料反复变化”的场景，如果每份材料都解一次细网格方程，就没有节省可言。

所以策略是：**把误差限制在一个低维子空间里近似**，

> $e \approx Z\,c$，　Z 为 $N\times r$，$r = 128 \ll N$

Z 的每一列是一个“修正方向”，c 是 r 维系数。问题拆成三件事：

1. **Z 从哪里来？** 由网络根据材料、当前解和残差生成（学习部分，只做一次）。
2. **c 怎么定？** 由当前离散方程解一个 128×128 的小系统（物理部分，每轮都做）。
3. **怎么让它便宜？** 先滤波把“容易消”的误差消掉，让 Z 只处理“难消”的部分；Z 与小系统分解在轮次间复用。

> **一句话：** 网络只负责“往哪些方向修”，方程负责“每个方向修多少”。

3　第一步：滤波，先把“振荡型”误差压掉

3.1　误差的“粗糙程度”怎么度量

考虑广义特征问题

> $A\,v = \lambda\,D\,v$，　$D = \mathrm{diag}(A)$

- λ 小：特征向量在 A-内积下“平滑”，对应大范围、缓变的误差；
- λ 大：特征向量“振荡”，对应细尺度、高频的误差；
- λ 的最大值记为 λ_U。

为什么用 $D^{-1}A$ 而不是 A？因为 $D^{-1}A$ 与对称正定的 $D^{-1/2}A\,D^{-1/2}$ 相似，特征值全为正实数，且量级被对角缩放控制在 O(1)。若不做这个缩放，λ_{max} 会随材料和对比度剧烈变化，滤波参数无法固定。

λ_U 不通过特征分解求，而用 Gershgorin 行界估计：

$$\lambda_U = (1 + 10^{-6}) \cdot \max_i \left(\Sigma_j |A_{ij}| / A_{ii} \right)$$

读法：第 i 行所有元素绝对值之和除以对角元，是 $D^{-1}A$ 第 i 行元素的绝对值之和；矩阵任一特征值都不超过这个行和的最大值。直角三角网格上它约等于 2；10^{-6} 只是防止浮点求和误差越界。

关键：滤波的所有参数都由当前矩阵算出来，不依赖“这是什么 PDE、什么材料”。

3.2 Chebyshev 多项式在做什么

滤波不是“解方程”，而是对当前解做固定步数的迭代。设 S_m 表示 m 步 Chebyshev 半迭代，误差传播为

$$\bar{e} = p_m(D^{-1}A)\, e, \qquad p_m(\lambda) = T_m((d - \lambda)/c) \,/\, T_m(d/c)$$

其中 T_m 是 m 次 Chebyshev 多项式，

$$d = (\lambda_U + \lambda_c)/2, \quad c = (\lambda_U - \lambda_c)/2, \quad \lambda_c \text{ 为截止值}$$

多项式的形状（理解滤波的关键）：

- $\lambda = 0$ 时 $p_m(0) = 1$：最平滑的分量不被衰减；
- λ 落在 $[\lambda_c, \lambda_U]$ 时，$|p_m(\lambda)| \leqslant 1/T_m(d/c)$：这一段被压到很小，并在正负之间等幅振荡；
- 因此它是一个高通抑制器：保留接近零的谱分量，压掉其余分量。

它还有性质：在整个谱区间上 $|p_m(\lambda)| \leqslant 1$，于是

$$\|\bar{e}\|_A = \|p_m(D^{-1}A)\, e\|_A \leq \|e\|_A$$

滤波在精确算术下不会让能量误差变大，这是它可以放在流程最前面、又不破坏后面校准单调性的原因。

3.3 递推公式怎么读

$$\rho_j = (2d/c - \rho_{j-1})^{-1}$$
$$\delta_j = (2\rho_j/c)\, D^{-1}(b - A\, x_j) + \rho_j \rho_{j-1} \delta_{j-1}$$
$$x_{j+1} = x_j + \delta_j$$

- $b - A\, x_j$：当前残差，每次迭代算一次；
- $D^{-1}(b - A\, x_j)$：对残差做对角缩放（Jacobi 预条件），让更新量量级正常；
- ρ_j：Chebyshev 递推系数，只依赖 λ_U、λ_c 和步数，不依赖当前解；
- δ_j：第 j 步的更新方向，带上一步的记忆；
- $x_{j+1} = x_j + \delta_j$：更新解。

成本：每一步只需一次稀疏矩阵乘 $A\, x_j$ 和一次对角缩放，O(s)，s 为非零元个数。64 步就是 64 次稀疏矩阵乘，没有分解、没有全局通信。

3.4 参数与效果

阶段	步数	截止值	作用
预滤波	64	$0.0005\, \lambda_U$	压掉高频振荡，改变剩余误差的分布
后滤波	8	$0.025\, \lambda_U$	清理投影后引入的局部粗糙分量

实测（8 份验证材料）：导数误差 45.38% → 4.36%，通量误差 77.56% → 5.24%；状态误差只从 1.54% 降到约 1%。这说明：

- 导数和通量误差主要由高频分量贡献，滤波对它们最有效；
- 状态误差主要由低频分量贡献，滤波几乎动不了它；剩下的“平滑但整体错”的误差，才是学习的对象。

一句话：滤波负责“能便宜消掉的”，它消不掉的那部分，交给低维响应空间。

4　第二步：响应字典，网络生成 128 个修正方向

4.1　输入：7 个通道

通道	含义	为什么需要
$\log a_i$ / $\log 12$	材料系数的对数（固定尺度 12 归一化）	把跨 10^4 的对比度压到 O(1)
相对中位数的对角对数	$\log D_{ii}$ − median(log D)	局部材料刚度
两个坐标	节点位置	边界与几何位置
相对中位数的节点质量对数	局部网格尺度	网格疏密
$\bar{x}_i$ / RMS($\bar{x}$)	滤波后的状态	当前解的形状
$(D^{-1}r)_i$ / RMS($D^{-1}r$)	滤波后的残差	还差在哪里

前四个描述“材料与几何”，后两个描述“当前任务”。没有后两个，网络只能生成通用方向；有了它们，才能针对当前样本的剩余误差生成方向。

4.2　多层图：为什么要“多尺度”

残差的结构跨尺度：有的分量在一个大区域内整体偏，有的只在材料界面附近偏。单一尺度的消息传递感受野有限。

1. 用聚合把细网格逐层粗化，得到 prolongation 矩阵 P_ℓ（粗→细）；
2. 限制算子取 R_ℓ^{+}：把 $|P_\ell|^{T}$ 按行归一化，即正权平均，避免正负抵消；
3. 每层的邻接 $\mathcal{G}_\ell$ 取“单位材料参考矩阵”的非对角绝对值并按行归一化；材料变化时复用，不重建图。

消息传递块：

> $$\mathcal{B}_\ell(H) = H + \mathrm{GELU}[\ \mathrm{LN}(\ H\,W_s + \mathcal{G}_\ell\,H\,W_n + b_s\ )\ ]$$

- $H\,W_s$：节点自身特征的线性变换；
- $\mathcal{G}_\ell\,H\,W_n$：邻居特征的加权平均（图上的扩散）；

- 两者相加，LayerNorm 归一化，GELU 加非线性；
- 外面的 $H + \cdots$：残差连接，保留原特征，训练更稳。

下行（细→粗）扩大感受野：

$$H_1 = \mathcal{B}_1{}^{\downarrow}(O_1), \quad H_\ell = \mathcal{B}_\ell{}^{\downarrow}(O_\ell + R_{\ell-1}{}^{+}H_{\ell-1})$$

读法：第 ℓ 层的特征 = 本层输入 O_ℓ + 更粗层特征的平均池化 $R^{+}H$，再过消息块。越往下，一个节点“看到”的范围越大。

上行（粗→细）把全局上下文带回细节：

$$U_\ell = \mathcal{B}_\ell{}^{\uparrow}[\ \mathrm{GELU}(\ [H_\ell,\ P_\ell U_{\ell+1}]\ W_{\mathrm{merge}} + b_{\mathrm{merge}}\ )\ ]$$

读法：把本层特征 H_ℓ 与粗层上采样 $P_\ell U_{\ell+1}$ 拼在一起，线性融合后再过消息块。下行所有层共用一套 (W_s, W_n)，上行共用另一套，所以参数量不随层数增长。

4.3　输出与“秩”的问题

$$\tilde{Z} = \tanh[\ P_0(\ U_1\ W_{\mathrm{out}} + 1\ b_{\mathrm{out}}{}^{T}\ )\ ]$$

为什么必须是非线性读出？如果最后一步是线性的，即 $\tilde{Z} = H\,W + 1\,b^{T}$，那么 $\mathrm{rank}(\tilde{Z}) \leqslant w + 1$。隐藏宽度 $w = 16$ 时，即使输出 128 个通道，这 128 列最多张成 17 维空间，多出来的通道是冗余的。加逐元素 tanh 后，每一列是隐藏特征的不同非线性函数，可以彼此独立。实测奇异值谱：线性读出在第 18 个方向断崖（秩 17），非线性读出铺满 128 维。

网络总共 3,952 个参数，与网格规模无关。

4.4　整形与归一化

得到 $\tilde{Z}$ 后，先做两次阻尼 Jacobi 平滑：

$$\tilde{Z}^{j+1} = \tilde{Z}^{j} - (4/(3\lambda_U))\ D^{-1}A\ \tilde{Z}^{j}, \quad j = 0,\ 1$$

读法：把每个方向的高频毛刺磨掉。$\lambda_U \approx 2$ 时系数 $4/(3\lambda_U) \approx 2/3$，正是经典阻尼 Jacobi 的权重。然后每列按 $\sqrt{(z_j{}^{T}A\ z_j)}$ 归一化，使每个方向的 A-能量为 1；各列量级一致，Gram 矩阵不会因为某列

特别大而病态。

> **一句话：**网络输出的是 128 个“磨平、归一化”的形状，不是解本身。

5　第三步：校准，方程决定每个方向修多少

5.1　从“最小能量”出发

离散问题的能量泛函是

$$\mathcal{E}(x) = \tfrac{1}{2}\, x^{T} A\, x - b^{T} x$$

它的梯度是 $A\,x - b = -r$，驻点就是 $A\,x = b$。现在限制修正只能发生在 Z 张成的空间里，即 $x + Z\,y$，并加一个很小的正则项：

$$c = \operatorname{argmin}_{y} \left[\, \mathcal{E}(x + Z\,y) + (\eta/2)\|y\|_{2}^{2} \,\right], \quad \eta = 10^{-5}$$

对 y 求导令其为零：

$$Z^{T} A (x + Z\,c) - Z^{T} b + \eta\, c = 0 \quad \Longrightarrow \quad (Z^{T} A\, Z + \eta\, I)\, c = Z^{T}(b - A\,x)$$

记

$$G = Z^{T} A\, Z, \quad H = G + \eta\, I, \quad q = Z^{T} r$$

就得到方法文档里的三行：

$$G = Z^{T} A\, Z, \quad H = G + \eta\, I, \quad H\,c = Z^{T}(b - A\,x), \quad x^{+} = x + Z\,c$$

5.2　每个符号在做什么

- G：128×128 的 Gram 矩阵，元素 $G_{ij} = z_i^{T} A\, z_j$，描述两个方向在能量内积下的耦合；
- $q = Z^{T} r$：把 N 维残差投影到 128 个方向上，得到“每个方向上还差多少”；

- $H = G + \eta I$：加正则，保证方向接近线性相关时也能稳定求解；
- c：每个方向的幅度；
- $x^+ = x + Zc$：用这 128 个方向组合出修正。

关键：网络只提供 Z，G 和 q 都由当前 A、b、x 算出。材料对比度变化时，幅度会自动按物理量级缩放；网络不需要学习“物理单位”。

5.3　几何解释：在子空间上做投影

把误差 e 看成一个 N 维向量，Z 的 128 列张成一个子空间。校准做的事，是把 e 投影到这个子空间上，只不过“垂直”是在 A-内积

$$\langle u, v\rangle_A = u^T A\, v$$

下定义的。$\eta \to 0$ 时，

$$Z\, c = Z\, (Z^T A\, Z)^{-1}\, Z^T A\, e = \Pi_A\, e$$

Π_A 是 A-正交投影算子。投影残差 $e - Z\, c$ 与子空间 A-正交，所以它是子空间内能量意义下最优的修正。

用一个一维例子把“方向 vs 幅度”说透。假设 Z 只有一列 z，最小化 $\tfrac{1}{2}\,\|\, e - c\, z \,\|^2$（$A$-范数）得

$$c = (z^T A\, e) \,/\, (z^T A\, z) = (z^T r) \,/\, (z^T A\, z)$$

如果把 z 放大 10 倍，分子分母同时放大 100 倍，c 缩小 10 倍，$c\, z$ 不变。**所以网络即使把方向的尺度搞错，也不影响结果；它只需要把“形状”学对**。这就是“方向由网络、幅度由方程”的精确含义。

5.4　能量不增的证明

记 $e = x^* - x$。由 $H\, c = q = Z^T A\, e$，有

$$
\begin{aligned}
&\|e - Zc\|_A^2 \\
&= \|e\|_A^2 - 2\, c^T Z^T A\, e + c^T G\, c \\
&= \|e\|_A^2 - 2\, c^T H\, c + c^T G\, c \\
&= \|e\|_A^2 - c^T G\, c - 2\eta \|c\|_2^2
\end{aligned}
$$

因为 G 半正定、$\eta > 0$，右边一定不超过 $\|e\|_A^2$。**每一步校准都不会让能量误差变大**；$\eta = 0$ 时正好是投影，误差严格不增。

> **一句话：**校准是一个带正则的 Galerkin 投影；它把“往哪修”交给网络，把“修多少”交给方程。

6　第四步：去偏，为什么多解一次小系统还能再好一点

正则项 η 让 H 稳定，但也让系数“缩水”了一点：真正的投影应该用 $G^{-1}q$，实际用的是 $(G+\eta I)^{-1}q$。两者差多少？利用恒等式

$$
G^{-1} = (I + \eta G^{-1})^{-1}\, H^{-1} = H^{-1} - \eta H^{-2} + \eta^2 H^{-3} - \cdots
$$

可以把“无正则解”写成无穷级数。方法只取前 t 项：

$$
d_0 = H^{-1} q, \quad d_{j+1} = H^{-1}(\eta\, d_j), \quad c_t = \Sigma_{j=0}^{t-1}\, d_j
$$

读法：d_0 就是原来的校准；d_1 是用同一个 Cholesky 分解再解一次得到的修正项；$c_2 = d_0 + d_1$ 就是两次小求解。每多一项只多一次三角回代，$O(r^2)$，不增加任何 A 的作用。

对 G 的特征值 λ，这个截断相对“理想投影”的增益是

$$
g_t(\lambda) = \lambda\, \Sigma_{j=0}^{t-1}\, \eta^j / (\lambda + \eta)^{j+1} = 1 - (\eta/(\lambda+\eta))^t \in [0, 1]
$$

- $\lambda \gg \eta$ 时，$\eta/(\lambda+\eta) \approx 0$，$g_1 \approx 1$：大特征值方向本来就没被正则影响，多解无益；
- $\lambda \sim \eta$ 时，$\eta/(\lambda+\eta) \approx 1/2$，$t = 2$ 把偏差从 1/2 降到 1/4；
- 所以去偏只对小特征值方向有效，这正是正则影响最大的地方。

实测：平滑 0.00415 → 0.00336，粗糙 0.00949 → 0.00787，六尺度 0.01383 → 0.01299；七个组合、16/16 样本全部改善，代价约 0.1–0.2 ms。

> **一句话：**去偏是把正则带来的“缩水”用小系统自身的级数补回来，不动大网格。

7　第五步：多轮与复用，为什么网络只调用一次

一轮的完整操作是：

1. 预滤波 S_{pre}；
2. 用当前残差做校准 $x \leftarrow x + Zc$；
3. 后滤波 S_{post}。

固定 Z、忽略 η 时，一轮的误差传播可以写成

$$e^{(k+1)} = S_{post}\,(I - \Pi_A)\,S_{pre}\,e^{(k)}$$

- S_{pre} 压掉高频分量（子空间不擅长表示的部分）；
- $I - \Pi_A$ 是投影后的残差，去掉子空间能覆盖的部分；
- S_{post} 再清理投影可能引入的局部粗糙分量。

三者复合是收缩算子，所以轮数越多误差越小。实测：K1 约 10^{-1}%，K2 约 10^{-2}%，K4 约 10^{-3}%。

为什么 Z 不每轮重算？因为 Z 由材料、初始状态和初始残差生成，后续轮次只改变 x，材料不变；实验显示复用同一 Z 到 K4 仍然收敛。复用带来两个好处：网络只调用一次（3.22 ms），Gram 与 Cholesky 只做一次（3.50 ms）；每轮只剩预滤波（4.26 ms）、小系统回代和后滤波。

> **一句话：**“一次设置、多轮使用”是成本优势的来源，也是与逐轮调用网络的混合方法的主要区别。

8　训练：为什么用对数损失、为什么展开四轮

训练时冻结神经算子，用它的真实预测经过预滤波后的状态作为输入。展开 K = 4 轮，损失是

$$\mathcal{L}(\theta) = (1/(3K)) \sum_{k=1}^{K} \sum_{j\in\{u,g,q\}} \log \max(E_j^{(k)}, 10^{-6})$$

- $E_j^{(k)}$：第 k 轮、第 j 个输出（状态/导数/通量）的相对误差；
- 对 k 求和：让网络对每一轮之后的误差都负责，而不是只管第一轮；
- 对 j 求和：三项物理输出同等重要，避免只优化状态；
- log：不同轮次误差差几个数量级（K1 约 10^{-1}，K4 约 10^{-3}），直接平均会被第一轮主导；取对数后各轮贡献均衡，后期小误差也能持续参与优化；
- $\max(\cdot, 10^{-6})$：防止 log 0，只影响数值安全。

梯度通过“空间生成 → 整形 → Gram → Cholesky → 更新”整条链路反传（BPTT）。验证集用同一目标选模。

一句话：训练目标不是“预测得准”，而是“四轮校正之后三项物理输出都准”。

9　为什么有效、什么时候失效：覆盖率

把误差做能量变换：$y = A^{1/2}e$，$Q = A^{1/2}Z$。投影后残差的能量是

$$\|(I - \Pi_Q)\, y\|_2^2, \quad \Pi_Q = Q\,(Q^TQ)^{\dagger}\,Q^T$$

如果误差来自某个分布，协方差 $C = E[y\, y^T]$，那么期望残差能量是

$$E\|(I - \Pi_Q)\, y\|_2^2 = \mathrm{tr}[\,(I - \Pi_Q)\, C\,]$$

读法：Z 好不好，不取决于它“看起来像不像解”，而取决于 C 的能量有多少落在 Q 张成的子空间里。这就是“任务覆盖”。

- 固定正弦空间对“最慢 16 个模态”的覆盖是 67.43%，但对实际误差分布只有 8.56%；
- 学习空间对慢模态的覆盖是 67.12%（几乎一样），但对实际误差是 77.70%。

所以“更好的通用低频基”不是答案；必须让空间依赖当前材料与残差。

失效条件：对比度从 6 外推到 60 时，相结构没变，但材料耦合强度变了，覆盖率从 79.06% 降到 57.15%，状态误差从 10^{-4} 量级升到 1.69%（K2）。增加小求解次数只把覆盖率提到 59.34%，说明缺

口在空间覆盖，不在幅度或求解精度。

三个物理误差为什么能被能量控制住：正系数给出

$$\alpha\|\nabla e\|_{L2}^2 \le \|e\|_a^2 \le \beta\|\nabla e\|_{L2}^2,\quad \alpha\|e\|_a^2 \le \|a\nabla e\|_{L2}^2 \le \beta\|e\|_a^2$$

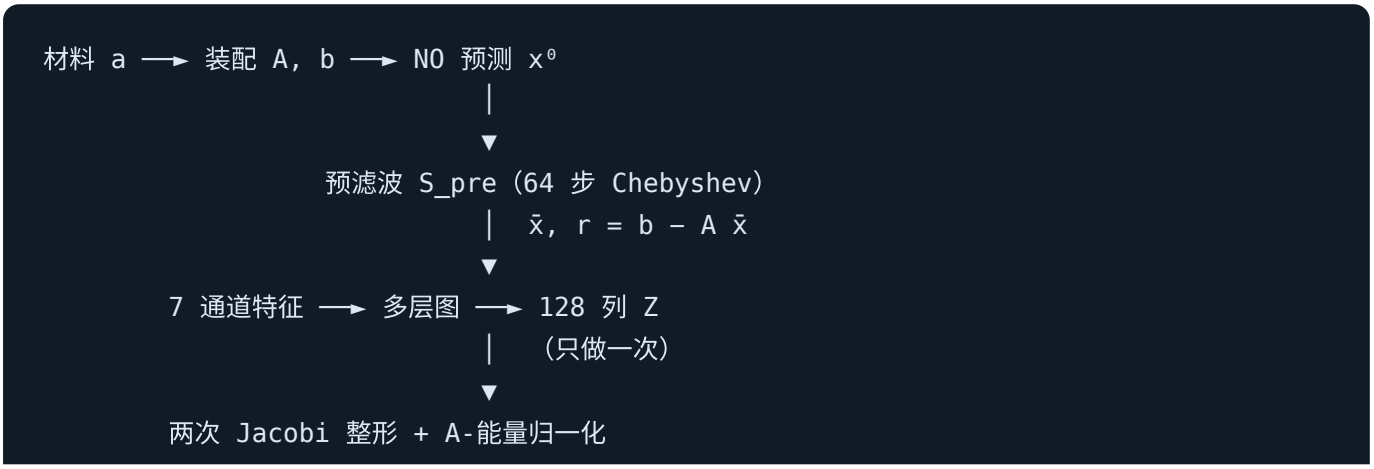
再由 Poincaré 不等式 $\|e\|_{L2} \le C_P\|e\|_a/\sqrt{\alpha}$。所以能量误差小，三个物理误差都小；但常数依赖对比度 β/α，高对比时能量误差可能掩盖更大的通量误差，这就是三项必须分别评价的原因。

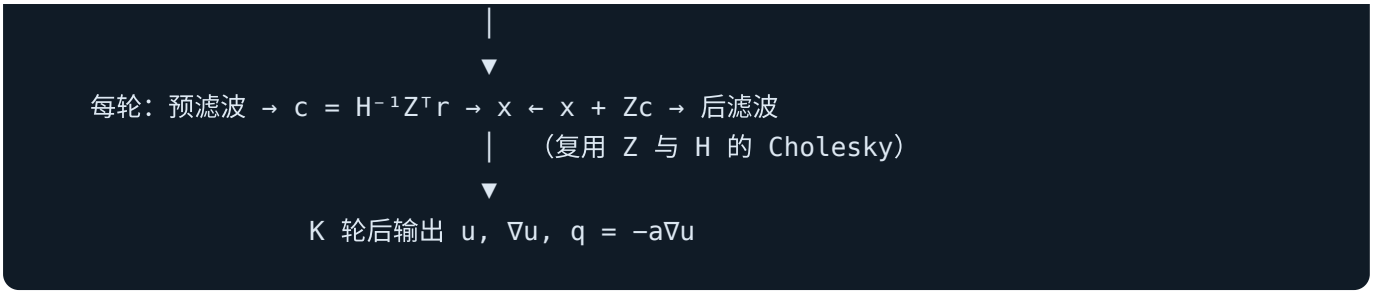
10　成本：每个公式对应多少计算

操作	复杂度	说明
$A Z$（128 列同时作用）	$O(s r)$	128 次稀疏矩阵乘
$G = Z^T A Z$	$O(N r^2)$	逐列累加 128×128
Cholesky 分解 H	$O(r^3)$	128^3，很小
每轮	$O(m s + N r + t r^2)$	m 次滤波 + 组合 + t 次回代
存储 Z	$O(N r)$	128 个 N 维向量

实测（六尺度 257^2，K2）：神经算子 2.20 ms、装配 0.75、预滤波 4.26、特征 0.43、图网络 3.22、Gram 与分解 3.50、校准与后滤波 5.28，完整 17.96 ms。

11　把公式串成一张图





如果只记五个公式，记这五个

1. $A\,e = r$：残差就是误差，方法的目标是近似 e；
2. $|p_m(\lambda)| \leqslant 1$：滤波不放大能量误差；
3. $G = Z^{T}A\,Z$，$H\,c = Z^{T}r$：校准的小系统；
4. $\| e - Zc \|_{A}^{2} = \| e \|_{A}^{2} - c^{T}G\,c - 2\eta \| c \|^{2}$：每轮能量不增；
5. $E \| (I - \Pi_{Q})y \|^{2} = \mathrm{tr}[(I - \Pi_{Q})C]$：性能由任务覆盖率决定。

12　几个常见的“看不懂”点，直接回答

Q1　为什么不直接解 $Ae = r$，而要学一个 Z?

因为解 $Ae = r$ 就是再做一次完整求解，材料反复变化时成本没有下降。Z 把“求解”换成了“在 128 维里选系数”，小系统 128×128 的代价可以忽略。

Q2　为什么用 $D^{-1}A$，不直接用 A?

$D^{-1}A$ 与对称正定矩阵相似，特征值为正、量级被对角缩放控制在 $O(1)$，$\lambda_U \approx 2$，滤波参数才能固定且与材料无关。用 A 的话，谱宽随对比度变化，多项式参数需要逐材料调。

Q3　η 能不能去掉?

能去掉，当 Z 的列线性无关且数值条件好时，$\eta = 0$ 就是纯投影。保留 $\eta = 10^{-5}$ 是为了在列接近相关时 Cholesky 稳定；代价是很小的幅值偏差，用第 6 节的去偏补回来。

Q4　为什么网络只调用一次，后面不重新生成 Z?

Z 的条件是材料、初始状态和初始残差；材料不变时，后续轮次只是 x 变了，方向空间仍然适用。实验上 K4 仍收敛；复用省掉了每轮的图网络与分解。

Q5　为什么不用 PCG?

固定轮次、无停止准则，是为了计时可比、空间与分解可复用。PCG 每轮需要新的 Krylov 空间，收敛速度又依赖材料条件数，会把“表示能力”和“迭代次数”混在一起。

Q6　128 维是怎么定的?

64 和 128 是两个容量工作点。128 维在秩诊断中已满秩，K2 到 10^{-2}%、K4 到 10^{-3}%；再增大维度，Gram 的 $O(Nr^2)$ 与存储 $O(Nr)$ 上升，收益递减。

Q7　为什么训练用 log，不用均方误差?

四轮展开后误差跨几个数量级，均方误差会被第一轮的大误差主导，后期 10^{-3} 的改善几乎不产生梯度；对数把各轮拉到同一尺度，后期小误差持续参与优化。

Q8　这个方法什么时候会失效?

当测试材料的剩余误差方向超出 Z 的覆盖时。对比度外推实验就是例子：覆盖率 79% → 57%，误差上升两个数量级；此时增加小求解次数或调幅都无效，需要把材料连接强度纳入方向生成。

13　公式与代码的对应

公式	函数	作用
λ_U 的 Gershgorin 界	`spectral_upper`	由当前矩阵算谱上界
$p_m(D^{-1}A)$ 与三项递推	`fixed_filter` → `chebyshev`	固定步数滤波
两次 Jacobi 整形、归一化、Gram/Cholesky	`calibrate_dictionary` → `factor_modes`	生成并分解响应空间
$Hc = Z^T r$、$x \leftarrow x + Zc$、去偏	`calibrated_update`	一轮校准
预滤波 → 校准 → 后滤波，重复 K 轮	`study.py: cycles`	固定轮次执行
展开四轮 + 对数损失	`study.py: train`	训练与选模